Más diccionarios

Ya vimos como implementar diccionarios usando ABB.

¿Que pasa si **no nos interesa** el orden de los datos?

Esto nos debería permitir complejidades menores que $O(\log n)$

Idealmente serían $O(1)$. ¿Qué estructura nos permite esto?

Dónde guardar una clave

¿Podremos guardar los datos en un arreglo?

¿En qué posición?

Debería depender solo de la clave. ¿Cómo hacemos esto?

Función de Hash

Una función de hash se define como sigue:

$$h : D \rightarrow \mathbb{N}_0$$

Donde D es el dominio de las claves.

Podemos usar esto para definir en que celda guardar una clave $key \in D$

Tabla de Hash

Como diccionario, guarda pares de la forma $(key, value)$

donde $key \in D$

Se implementa como un arreglo T de tamaño m

El par (k, v) se guarda en $T[h(k)]$. ¿Qué pasa si $h(k) > m$?

Método de la división

Simplemente, usar el módulo:

$$h'(k) = h(k) \bmod m$$

Por lo tanto, (k, v) se guarda en $T[h'(k)]$

Se recomienda que m sea un número primo

Método de la multiplicación

Sea A un número entre 0 y 1:

$$h'(X) = \lfloor m \cdot (A \cdot h(X) \bmod 1) \rfloor$$

Por lo tanto, (k, v) se guarda en $T[h'(k)]$

Se recomienda $A = \frac{1}{\varphi}$

Colisiones

Si $A \neq B$,

Decimos que una función de hash produce una **colisión** si

$$h(A) = h(B)$$

Además, diremos que existe una **colisión en la tabla** si

$$h'(A) = h'(B)$$

Una colisión en la tabla **no implica** una colisión en la función

Manejo de colisiones

En ambos casos, A y B caen en la misma celda de la tabla

¿Cómo podemos guardar ambos datos en la tabla?

Nos interesa poder buscarlos en el futuro

Direccionamiento abierto

Podemos buscar otra celda que esté disponible

¿Dónde la buscamos?

Debemos seguir alguna regla

Una posible regla: Sondeo lineal

$m = 7$

Insertemos la *A*

$h(\mathrm{A}) = 15;\ 15 \bmod 7 = 1$

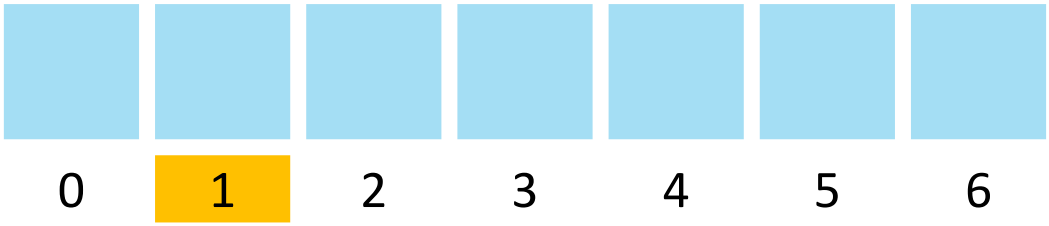

...

$m = 7$

Insertemos la *A*

$h(\mathrm{A}) = 15;\ 15 \bmod 7 = 1$

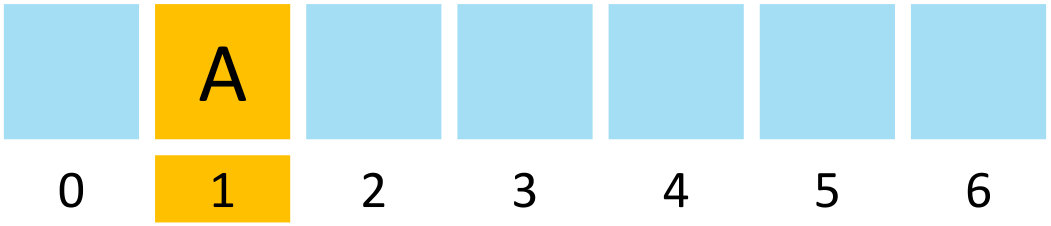

...

$m = 7$

Insertemos la Q

$h(Q) = 37;\ 37 \bmod 7 = 2$

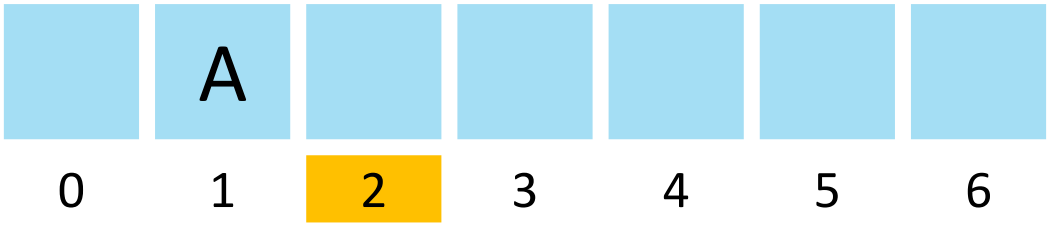

...

$m = 7$

Insertemos la Q

$$h(Q) = 37$$

$37 \bmod 7 = 2$

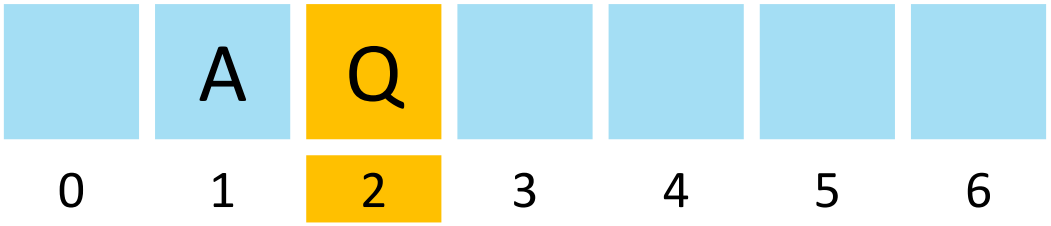

...

$m = 7$

Insertemos la *L*

$h(L) = 51;\ 51 \bmod 7\ = 2$

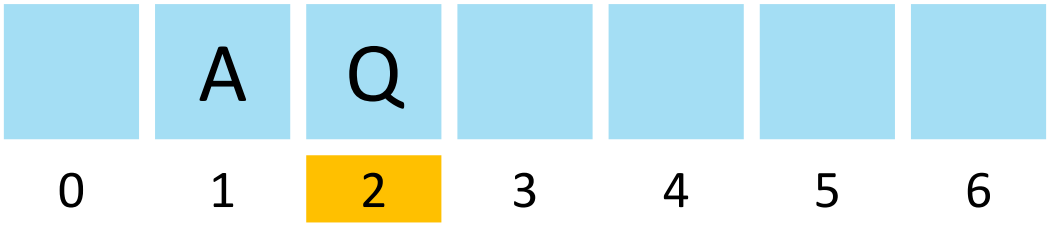

...

$m = 7$

Insertemos la *L*

$h(L) = 51;\ 51 \bmod 7\ = 2$

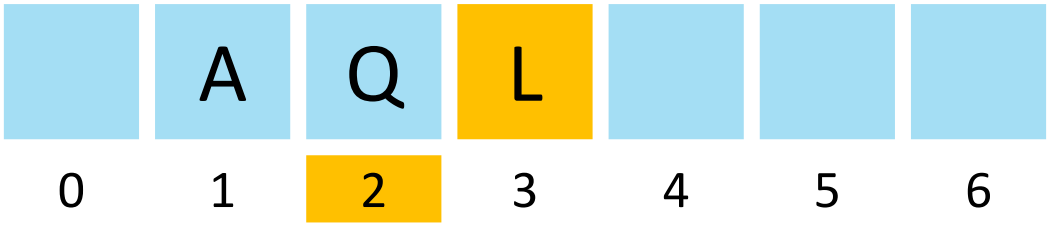

...

$m = 7$

Insertemos la *X*

$h(X) = 29;\ 29 \bmod 7\ = 1$

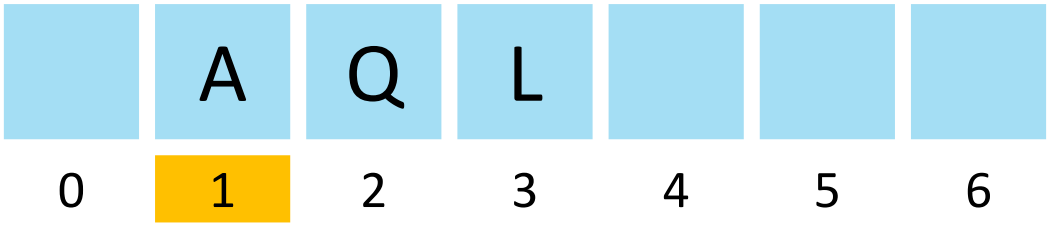

Fin del ejemplo

$m = 7$

Insertemos la *X*

$h(X) = 29;\ 29 \bmod 7\ = 1$

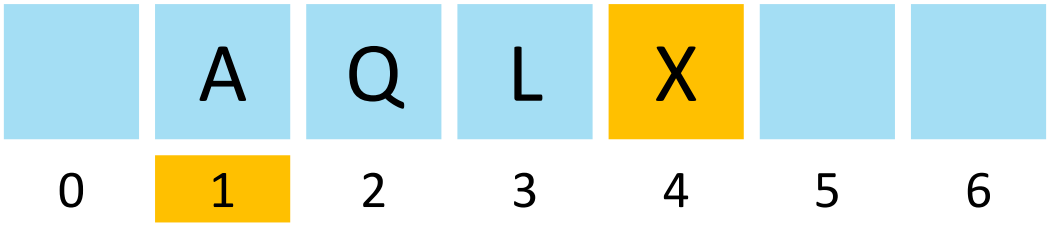

Otras posibles reglas

Métodos populares de direccionamiento abierto son:

- Sondeo lineal:
  - buscar en $H,\ H+1,\ H+2,\ H+3$ …
- Sondeo cuadrático:
  - buscar en $H,\ H+1c_1+1^2c_2,\ H+2c_1+2^2c_2$ …
- *Double hashing*:
  - buscar en $h_1(k), h_1(k)+h_2(k), h_1(k)+2h_2(k),$ …

Búsqueda exitosa bajo sondeo lineal

$m = 7$

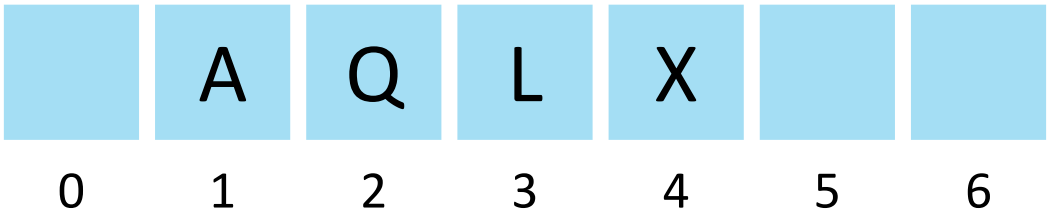

¿Cómo buscamos la *X* con sondeo lineal?

$h(X) = 29;\ 29 \bmod 7 = 1$

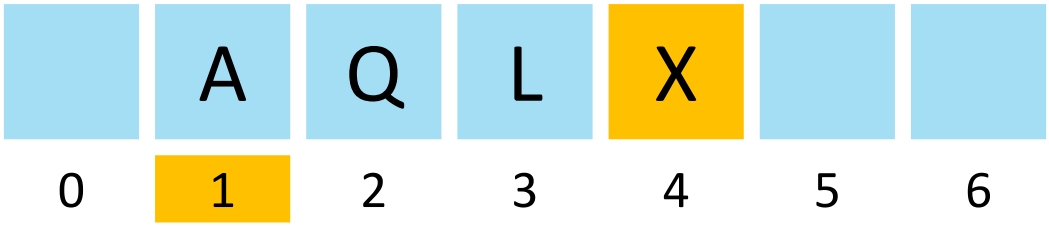

Búsqueda de un dato que no está

$m = 7$

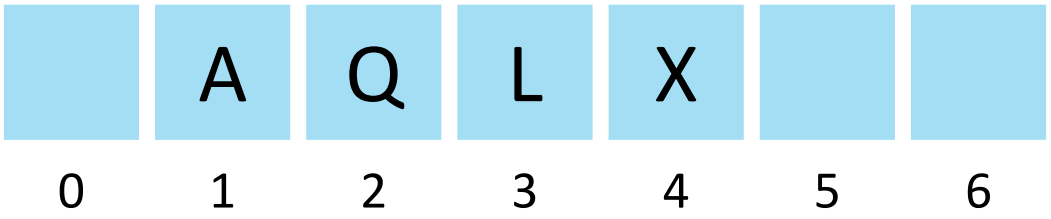

¿Cómo buscamos la *R* con sondeo lineal?

$h(R) = 10;\ 10 \bmod 7 \ = 3$

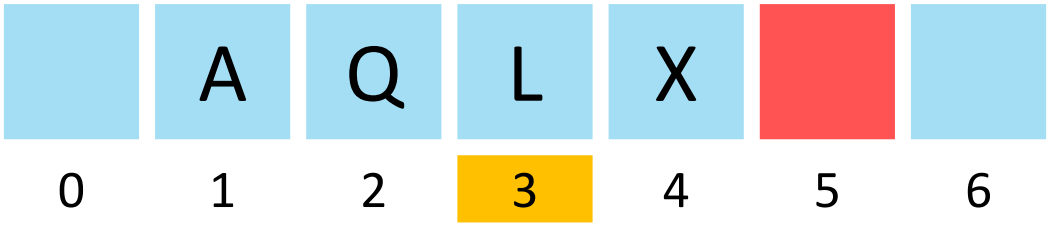

Problemas del direccionamiento abierto

Este esquema no permite eliminar datos de la tabla

¿Por qué?

La eliminación es problemática

$m = 7$

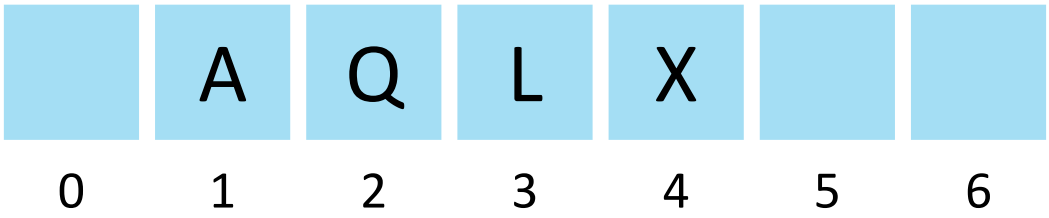

Eliminemos la *L*. ¿Cómo buscamos la *X* con sondeo lineal?

$h(X) = 29;\ 29 \bmod 7\ = 1$

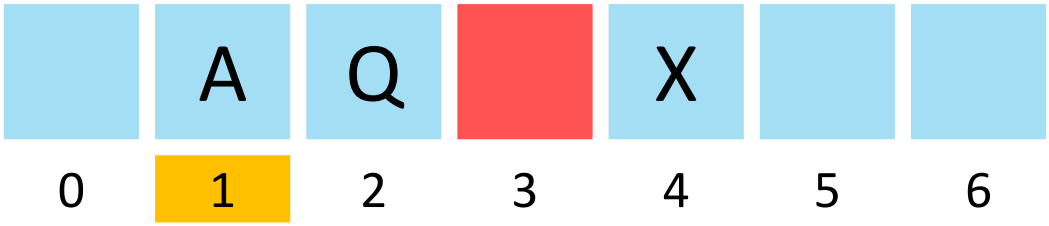

Otra posibilidad

Si A ya estaba en la tabla:

Podemos guardar A y B en la misma celda…

… pero ¡dentro de otra estructura de datos!

Encadenamiento

Por ejemplo, si tenemos una **lista** en cada celda de la tabla

Hemos guardado n datos, y la tabla es de tamaño m

Encadenamiento: ejemplo

$m = 7$

Insertemos la *A*

$h(A) = 15;\ 15 \bmod 7 = 1$

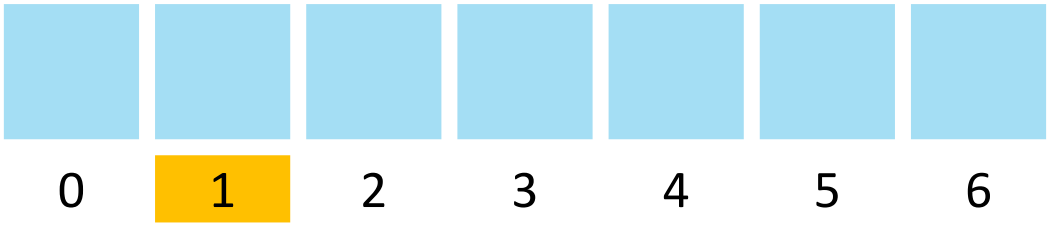

Sigue el ejemplo

$m = 7$

Insertemos la *A*

$h(A) = 15;\ 15 \bmod 7 = 1$

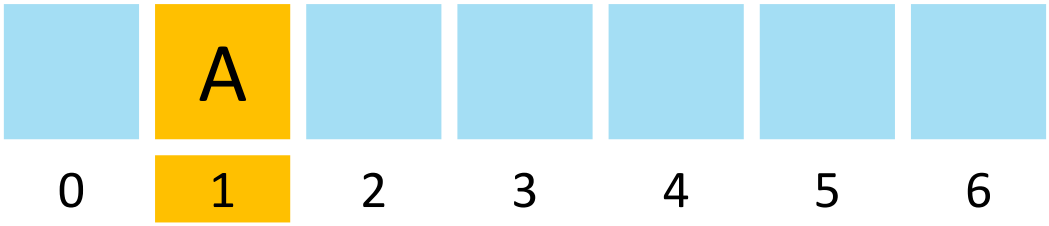

...

$m = 7$

Insertemos la Q

$h(\mathrm{Q}) = 37;\ 37 \bmod 7 \ = 2$

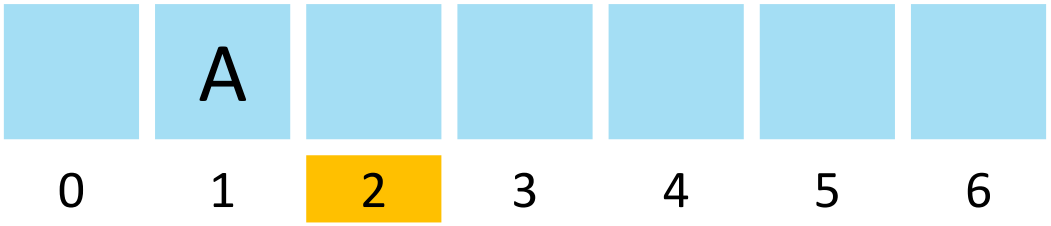

...

$m = 7$

Insertemos la Q

$h(Q) = 37;\ 37 \bmod 7\ = 2$

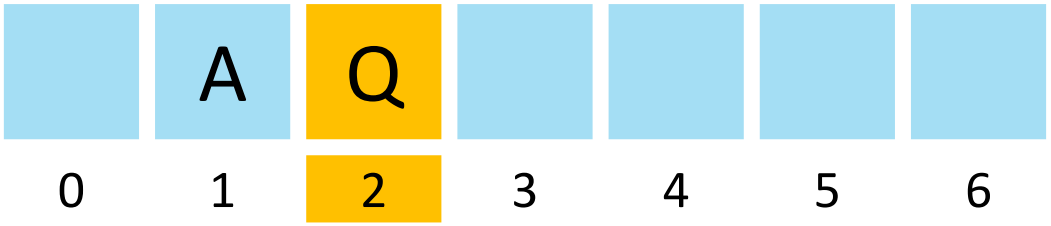

...

$m = 7$

Insertemos la *L*

$h(L) = 51;\ 51 \bmod 7\ = 2$

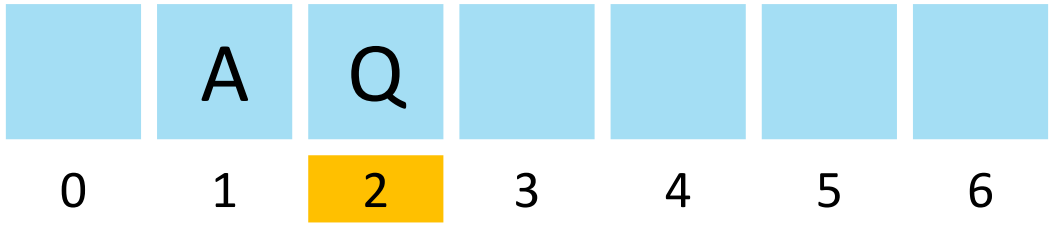

...

$m = 7$

Insertemos la *L*

$h(L) = 51;\ 51 \bmod 7\ = 2$

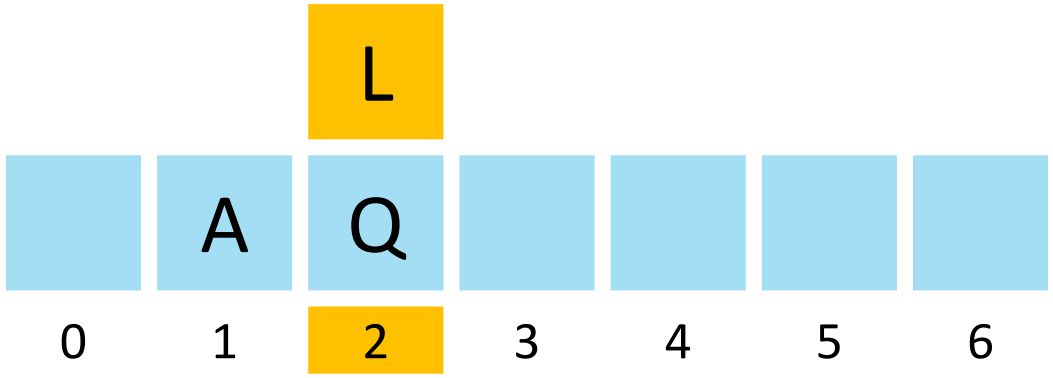

...

$m = 7$

Insertemos la *X*

$h(X) = 29;\ 29 \bmod 7\ = 1$

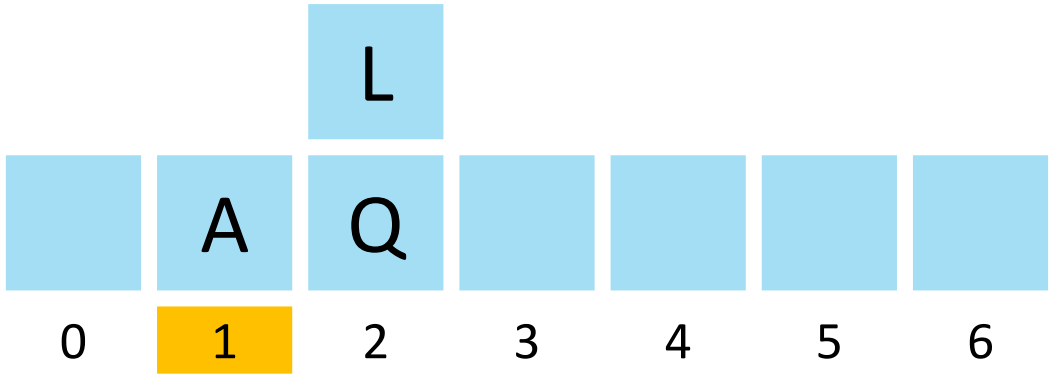

...

$m = 7$

Insertemos la *X*

$h(X) = 29;\ 29 \bmod 7\ = 1$

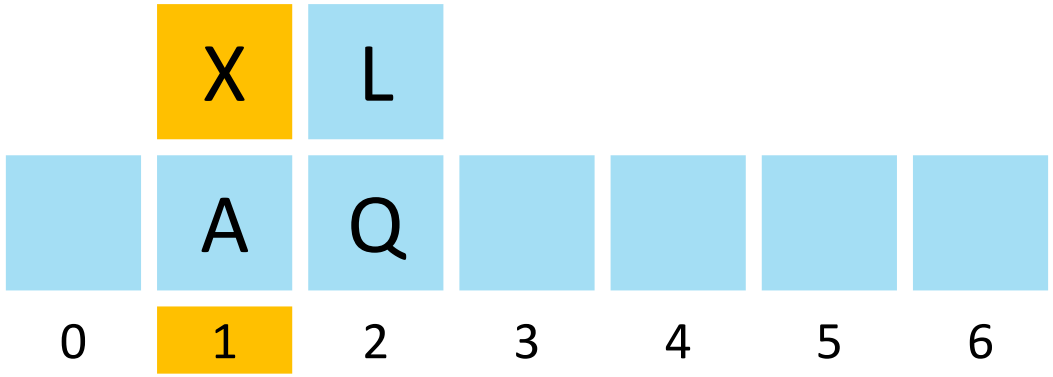

...

$m = 7$

Insertemos la *F*

$h(F) = 58;\ 58 \bmod 7\ = 2$

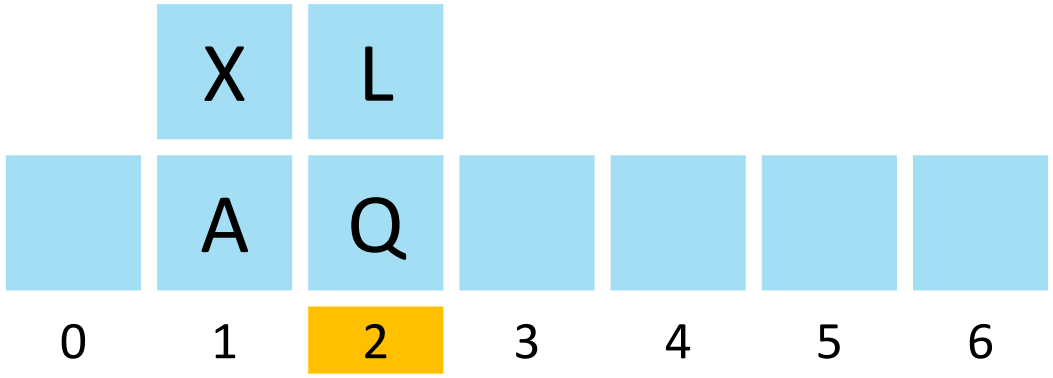

Fin del ejemplo

$m = 7$

Insertemos la *F*

$h(F) = 58;\ 58 \bmod 7\ = 2$

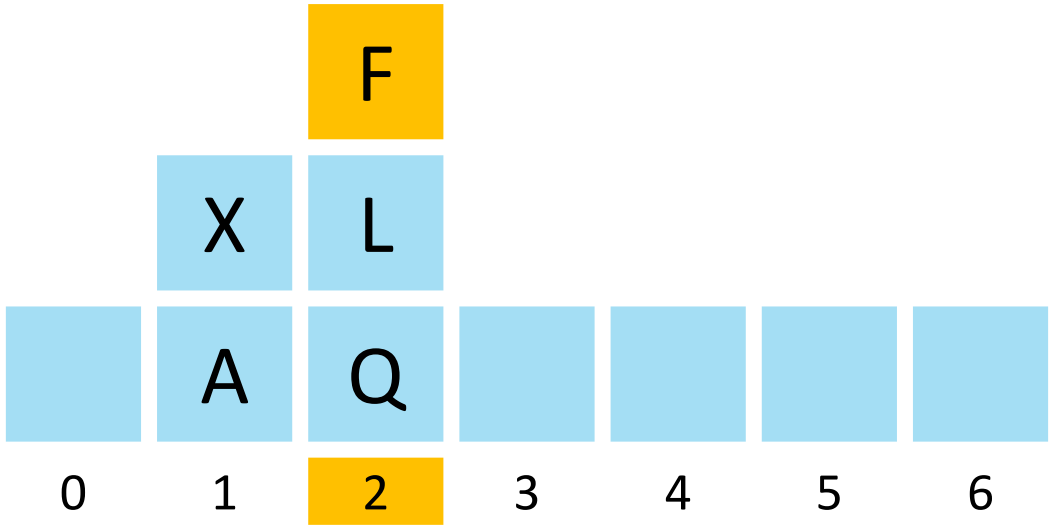

Factor de carga

Sea n la cantidad de claves almacenadas en la tabla

Se define el factor de carga λ como:

$$\lambda = \frac{n}{m}$$

Podemos fijar un valor λ_{max}, y garantizar que

$$\lambda < \lambda_{max}$$

Rehashing

Si $\lambda < \lambda_{max}$, en algún momento hay que hacer crecer la tabla

A este proceso se le dice **rehashing**

¿Cuál es su complejidad?

En resumen

Para implementar una tabla debemos entonces:

- Identificar el dominio de las claves
- Diseñar una función de hash para ese dominio
- Definir que hacer con los valores que se salen de la tabla
- Definir un esquema de resolución de colisiones
- Elegir un λ_{max} para garantizar eficiencia